

Análise e previsão de receitas no varejo: comparação entre modelos SARIMA e XGBoost

Jhonatan Zhang Deng¹, Rogério de Oliveira^{1,2}

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie São Paulo, SP – Brasil

²Programa de pós-graduação em Computação Aplicada – Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

10389471@mackenzista.com.br, rogerio.oliveira@mackenzie.br

Abstract. *The retail sector faces constant challenges due to the volatile and seasonal nature of its revenues, influenced by changes in consumer preferences and the economic environment. The growing need to improve the accuracy of financial forecasts in this context motivated this study, which aimed to analyze and predict monthly revenues for different product categories using the SARIMA and XGBoost models. The results indicated that the SARIMA model was effective for short-term forecasts but lost accuracy in longer-term predictions. On the other hand, XGBoost stood out for medium-term predictions.*

Resumo. *O setor varejista enfrenta desafios constantes devido à natureza volátil e sazonal de suas receitas, influenciadas por mudanças nas preferências dos consumidores e no ambiente econômico. A crescente necessidade de melhorar a precisão das previsões financeiras nesse contexto motivou este estudo, que teve como objetivo analisar e prever as receitas mensais de diferentes categorias de produtos, utilizando os modelos SARIMA e XGBoost. Os resultados indicaram que o modelo SARIMA foi eficaz para previsões de curto prazo, mas perdeu precisão em previsões mais longas. Por outro lado, o XGBoost se destacou em previsões de médio prazo.*

1. Introdução

A crescente concorrência no mercado varejista, impulsionada por consumidores cada vez mais exigentes e informados, aliada à diversidade de produtos e perfis de consumo, força as empresas a adotarem diversas estratégias e formatos [Santos and Costa 1997]. Nesse contexto, a previsão de vendas e receitas surge como uma ferramenta essencial para a otimização da gestão de estoques e operações logísticas. Um controle eficiente das receitas permite atender à demanda de forma equilibrada, evitando tanto excesso quanto escassez de produtos, o que contribui para a eficiência operacional e para a satisfação do cliente. A previsão de receitas é um aspecto central do planejamento financeiro e logístico das empresas, sendo uma das principais ferramentas para embasar a tomada de decisões estratégicas [Holanda et al. 2022, Pinto et al. 2013]. Martins e Alt (2006) destacam que a gestão eficaz das receitas é fundamental para alcançar os objetivos organizacionais, assegurando a alocação adequada dos recursos necessários [Holanda et al. 2022].

Nesse cenário, modelos preditivos, como o SARIMA (Seasonal Autoregressive Integrated Moving Average) e o XGBoost (eXtreme Gradient Boosting), mostram-se eficazes para prever séries temporais, permitindo que as empresas antecipem variações no

mercado e otimizem suas operações [Chen and Guestrin 2016, Silveira et al. 2019]. No entanto, a escolha do modelo preditivo mais adequado ainda é um desafio, especialmente considerando as particularidades das séries temporais de receitas, que frequentemente apresentam tendências e sazonalidades complexas [Hyndman 2018]. Assim, este trabalho tem como objetivo comparar a eficácia dos modelos SARIMA e XGBoost na previsão de receitas mensais no setor varejista, analisando dados históricos de receitas de uma empresa do setor para avaliar qual modelo oferece previsões mais precisas. A análise considera as características das séries temporais, como tendências e sazonalidades, e utiliza métricas de erro, como o erro percentual absoluto médio (MAPE), para avaliar o desempenho dos modelos.

Para alcançar o objetivo proposto, este estudo se divide em etapas que incluem a coleta de dados históricos de receitas da empresa varejista, seguida por uma fase de limpeza e tratamento dos dados. A análise exploratória identifica padrões sazonais e tendências nas séries temporais, proporcionando uma base sólida para a construção dos modelos preditivos. Os modelos SARIMA e XGBoost são implementados e seus desempenhos são comparados utilizando métricas de erro, permitindo uma avaliação robusta da eficácia de cada abordagem. A validação dos resultados assegura a precisão das previsões, contribuindo para uma análise conclusiva sobre a adequação dos modelos.

Desse modo este trabalho traz três contribuições principais:

1. **Comparação de modelos:** analisa e compara métodos de previsão estatísticos e de aprendizado de máquina aplicados ao problema de previsões de vendas e receitas no varejo.
2. **Disponibilização de modelo preditivo:** identifica o melhor modelo para previsão de receitas no curto prazo (1-3 meses) e disponibiliza-o de modo aberto para a comunidade.
3. **Repositório público:** todo o código e materiais utilizados neste estudo estão disponíveis no repositório GitHub, permitindo acesso aberto para replicação e estudos futuros [Jhonatan 2024].

A estrutura deste trabalho está organizada da seguinte forma: na Seção 2, apresenta-se a fundamentação teórica e os trabalhos correlatos a este estudo; na Seção 3, detalham-se a metodologia e as etapas de desenvolvimento do projeto; na Seção 4, discutem-se os resultados obtidos, abrangendo a criação do modelo, a análise dos experimentos e as respectivas interpretações; e, na Seção 5, realizam-se as considerações finais, além de sugestões de melhorias e propostas para trabalhos futuros.

2. Referencial Teórico

Este capítulo apresenta uma visão geral sobre o mercado varejista, destacando os desafios e as estratégias adotadas para lidar com a crescente competitividade. Em seguida, revisa os trabalhos relacionados que aplicaram diferentes modelos de previsão em variados contextos, ressaltando as contribuições e avanços proporcionados. Também são abordados os fundamentos teóricos das abordagens utilizadas neste estudo e por fim, são introduzidas as principais métricas de avaliação de desempenho, essenciais para a análise comparativa e validação dos modelos propostos.

2.1. Mercado de varejo

O setor de varejo enfrenta desafios cada vez mais complexos, devido a crescente concorrência e pelos consumidores cada vez mais informados e exigentes, que agora têm acesso a variedade de opções. Essa dinâmica tem levado as empresas a adotar diferentes estratégias para se diferenciarem no mercado, resultando em uma convergência de modelos de negócios no setor. A intensa competição, tanto no cenário global quanto nacional, tem forçado as empresas a repensarem os formatos tradicionais de lojas e serviços, ampliando suas operações para além dos métodos convencionais. Hoje, as vantagens competitivas estão cada vez mais ligadas à gestão eficiente de custos, à qualidade do atendimento e aos serviços prestados, em vez de depender exclusivamente da diversidade de produtos e da variação de preços, que se tornaram cada vez mais semelhantes entre os concorrentes [Santos and Costa 1997].

Segundo Porter (2019), as empresas podem conquistar uma vantagem competitiva por meio da inovação, que pode se manifestar na criação de novos produtos, serviços, processos ou abordagens inovadoras, sempre fundamentadas em estratégias e atividades de marketing [Botelho and Guissoni 2016]. Nesse sentido, os varejistas precisam administrar seus recursos de forma estratégica para aprimorar suas capacidades operacionais e, assim, alcançar vantagens competitivas sustentáveis.

Empresas como o Wal-Mart têm se destacado por adotar preços extremamente baixos, o que, por vezes, gera desconfiança entre os consumidores. Por outro lado, marcas como Sony, Nike e Apple preferem criar ambientes exclusivos, apostando em lojas de luxo com produtos de maior qualidade, focando na diferenciação pela experiência de compra. Diante desse cenário de transformações no comportamento do consumidor e nas estratégias adotadas pelas empresas, analisar as tendências emergentes e adaptar as estratégias de negócios se torna cada vez o diferencial para o sucesso no setor [Las Casas and Garcia 2007].

Nesse contexto de transformação constante e alta competitividade, a análise de dados se revela uma estratégia fundamental para otimizar as operações e aprimorar a experiência do consumidor. A previsão de séries temporais surge como uma ferramenta valiosa, permitindo que as empresas antecipem tendências de consumo e comportamentos de vendas. Com base em dados históricos, essa abordagem possibilita a adaptação de estratégias empresariais de maneira mais eficiente, garantindo uma gestão proativa e mais assertiva no processo de tomada de decisões.

2.2. Trabalhos relacionados

Diversos estudos destacaram a eficácia do modelo SARIMA na previsão de séries temporais em diferentes setores, especialmente para dados com padrões sazonais. Walter et al. (2013) aplicaram o modelo para prever vendas de motocicletas no Brasil, enquanto Lima et al. (2019) validaram sua utilização na projeção de demanda no setor calçadista. Silveira et al. (2019) compararam o desempenho do SARIMA com o algoritmo XGBoost em previsões de demanda no varejo, evidenciando vantagens do XGBoost em precisão. Oliveira et al. (2024) analisaram receitas públicas e destacaram a eficiência do SARIMA para transferências correntes. Por fim, Divisekara et al. (2020) demonstraram sua aplicabilidade na previsão de preços de commodities agrícolas, considerando sazonalidade e volatilidade.

A Tabela 1 apresenta um resumo desses estudos, ressaltando os contextos de aplicação e os métodos empregados.

Referência	Resumo	Modelos Empregados
Walter et al. (2013)	Aplicação do SARIMA para prever vendas de motocicletas no Brasil entre 2006 e 2010, com previsão para 2011, utilizando métricas como AIC e U-Theil.	Modelo SARIMA
Lima et al. (2019)	Previsão da demanda no setor calçadista com base em dados mensais de vendas, avaliando o modelo com métricas como MAPE e BIC.	Modelo SARIMA
Silveira et al. (2019)	Comparação entre SARIMA e XGBoost para previsão de demanda no varejo, destacando a maior precisão do XGBoost na otimização da cadeia de suprimentos.	SARIMA e XGBoost.
Oliveira et al. (2024)	Estudo comparativo de modelos econométricos e redes neurais para previsão de receitas correntes no estado de Alagoas.	SARIMA e redes neurais.
Divisekara et al. (2020)	Previsão de preços semanais de lentilhas vermelhas (2010–2019) considerando sazonalidade e volatilidade.	SARIMA (2,1,2)(0,1,1)[52].

Tabela 1. Resumo de estudos relacionados

2.3. Previsão de séries temporais

Uma série temporal é composta por uma sequência de observações coletadas em intervalos regulares de tempo. Esses dados podem abranger diversas áreas, como o PIB anual, preços diários de ações, volume de vendas mensais, entre outros. A periodicidade das séries temporais pode variar consideravelmente, de milissegundos a décadas, sendo amplamente aplicada em áreas como física, biomedicina, astronomia e geologia [de Oliveira et al. 2024].

Entre as principais tarefas no tratamento de séries temporais, destacam-se a previsão de valores futuros, a compreensão dos mecanismos subjacentes à série, a descrição de seu comportamento, a identificação de padrões sazonais e cíclicos, além da detecção de anomalias. A previsão de valores futuros é uma das aplicações mais comuns, frequentemente realizada por meio de modelos probabilísticos baseados no tempo, como AR, MA, ARIMA e SARIMA. Esses modelos são considerados paramétricos, ou seja, eles dependem de um número finito de parâmetros para representar os dados da série ao longo do tempo [de Oliveira et al. 2024].

Dentro do contexto das séries temporais, os padrões mais frequentemente identificados incluem tendência, sazonalidade e ciclicidade. A tendência refere-se a um movimento de longo prazo dos dados, que pode ser crescente ou decrescente, e nem sempre segue um comportamento linear. A sazonalidade, por sua vez, ocorre quando a série é influenciada por fatores sazonais, como variações sazonais anuais ou mensais, ou ainda dias específicos da semana, com uma frequência fixa e previsível. Já a ciclicidade se caracteriza por flutuações de longa duração, que não seguem uma periodicidade fixa, frequentemente associadas a fatores econômicos, como o ciclo de negócios, com uma duração superior a dois anos. A identificação desses padrões é importante para a esco-

lha de métodos adequados de previsão, pois permite selecionar abordagens que consigam capturar com precisão as variações observadas na série temporal [Hyndman 2018].

A previsão de séries temporais no varejo envolve a análise de dados históricos para identificar padrões como tendência, sazonalidade e ciclicidade, visando prever a demanda futura. Modelos tradicionais como ARIMA e SARIMA são amplamente usados para capturar essas características, enquanto técnicas de machine learning, como o XG-Boost, lidam melhor com dados complexos e grandes volumes. Prever com precisão as vendas ajuda a otimizar o estoque, evitando excessos ou faltas, e também facilita o planejamento de estratégias de marketing e precificação, garantindo a eficiência operacional e competitividade das empresas.

2.4. Modelos estatísticos: SARIMA

O modelo SARIMA (Seasonal Autoregressive Integrated Moving Average) foi desenvolvido para capturar padrões sazonais em séries temporais, ou seja, padrões que se repetem em intervalos periódicos, como dias, meses ou anos. Ele integra componentes tanto sazonais quanto não sazonais, oferecendo uma abordagem robusta para previsão.

A estrutura do modelo SARIMA pode ser expressa pela fórmula a seguir, conforme apresentado em [Hyndman 2018, de Oliveira et al. 2024, Box et al. 2015]:

$$\text{SARIMA}(p, d, q)(P, D, Q)_m \quad (1)$$

Onde:

- p : Refere-se à ordem da componente autoregressiva (AR), que envolve a dependência da série com seus próprios valores passados (lags).
- d : Indica o número de diferenciações necessárias para tornar a série temporal estacionária, ou seja, remover tendências ou sazonalidades de longo prazo.
- q : Representa a ordem da média móvel (MA), que captura as relações entre a série de dados e os erros residuais (ou desvios).
- P, D, Q : São as versões sazonais dos parâmetros AR, d , e MA, respectivamente, sendo responsáveis por modelar os mesmos efeitos, mas dentro de ciclos sazonais.
- m : Define o período da sazonalidade.

A equação ajustada pelo modelo SARIMA pode ser escrita como:

$$W_t = c + \left(\underbrace{\phi_1 W_{t-1} + \dots + \phi_p W_{t-p}}_{p \text{ - termos autorregressivos}} + \underbrace{\theta_1 e_{t-1} + \dots + \theta_q e_{t-q}}_{q \text{ - termos de médias móveis}} \right) + \quad (2)$$

$$+ \left(\underbrace{\Phi_1 W_{t-m} + \dots + \Phi_P W_{t-Pm}}_{P \text{ - termos sazonais autorregressivos}} + \underbrace{\Theta_1 e_{t-m} + \dots + \Theta_Q e_{t-Qm}}_{Q \text{ - termos sazonais de médias móveis}} \right) + e_t \quad (3)$$

Nesta equação, W_t representa a série temporal ajustada pelas diferenciações d e D . $W_t = \Delta^d Y_t$ corresponde à série após d diferenciações $W_t = Y_t - Y_{t-d}$. m ajusta a componente sazonal indicando o período. O termo e_t é o ruído branco, e os coeficientes $\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q, \Phi_1, \dots, \Phi_P$ e $\Theta_1, \dots, \Theta_Q$ são valores estimados durante o ajuste do modelo [Oliveira et al. 2024].

Essa fórmula captura a interação entre componentes não sazonais e sazonais, permitindo ao SARIMA modelar tanto padrões de longo prazo quanto efeitos sazonais, destacando sua aplicabilidade em diferentes contextos, como previsão de vendas, demandas e receitas.

2.5. Modelos de aprendizado de máquina: XGBoost

O XGBoost (eXtreme Gradient Boosting) é uma biblioteca de aprendizado de máquina de código aberto, distribuída, que emprega o algoritmo de boosting com árvores de decisão. [Eda Kavlakoglu 2024].

Desde seu impacto inicial em 2015, o XGBoost tem sido amplamente utilizado em competições de aprendizado de máquina, como as organizadas pelo Kaggle. No ano de 2015, das 29 soluções vencedoras publicadas no blog do Kaggle, 17 adotaram o XGBoost em seus modelos, sendo que, em 8 dessas soluções, o XGBoost foi utilizado exclusivamente. Essas conquistas demonstraram a eficácia do XGBoost em problemas como a previsão de vendas de lojas, destacando sua capacidade de lidar com dados complexos e alcançar resultados de ponta [Chen and Guestrin 2016].

No contexto deste trabalho, o XGBoost é empregado para a previsão de receitas no varejo, utilizando lags como variáveis preditoras. O conceito de *lags* refere-se ao uso de valores passados da série temporal como *features* para prever valores futuros. Nas séries temporais aplicadas aos modelos de Aprendizado de Máquina, as defasagens de períodos anteriores, isto é, $X = y_{t-1}, y_{t-2}$, etc., (Tabela 2) são empregadas como as variáveis preditoras do valor alvo y_t e que permite capturar aos padrões essenciais de tendência e sazonalidade dos dados [Holbrook 2020].

Tabela 2. Conjunto de Dados de Séries Temporais com Lags para o Aprendizado de Máquina.

y_t		X			
t	y_t	y_{t-1}	y_{t-1}	...	y_{t-n}
1	10	-	-		-
2	15	10	-		-
3	18	15	10		-
4	20	18	15	...	10
...				...	
m	22	20	18		15

Para otimizar a seleção dos lags no modelo, realiza-se uma análise detalhada das autocorrelações, visando identificar as defasagens mais relevantes. A autocorrelação parcial, em particular, é útil para determinar quais lags fornecem informações únicas, eliminando redundâncias e contribuindo para a melhoria da performance do modelo [Holbrook 2020].

Dessa forma, o XGBoost, ao ser combinado com a utilização de lags como variáveis preditoras, se apresenta como uma ferramenta importante para a previsão de receitas no varejo.

2.6. Métricas dos Modelos

A comparação entre os modelos de previsão será realizada utilizando um conjunto de métricas de erro que permitem avaliar a precisão das previsões e a consistência dos modelos. As métricas escolhidas para esta análise são o RMSE (Root Mean Squared Error), o MAPE (Mean Absolute Percentage Error), o MedAE (Median Absolute Error) e o AIC (Akaike Information Criterion)[Scikit-learn 2024, Zajic 2022].

O RMSE penaliza erros maiores ao elevar os erros ao quadrado, sendo útil quando se deseja minimizar os erros mais significativos. Quanto menor o valor do RMSE, melhor o modelo. Ele é calculado pela fórmula:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

onde y_i são os valores reais e \hat{y}_i são os valores previstos. O RMSE fornece uma medida da magnitude média do erro, sendo mais sensível a grandes discrepâncias entre os valores observados e previstos.

O MAPE calcula o erro médio em termos percentuais, permitindo comparar modelos com diferentes magnitudes de dados. Ele é dado pela fórmula:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100$$

Quanto menor o valor do MAPE, melhor a precisão do modelo. O MAPE fornece uma visão clara da precisão média do modelo, expressa como uma porcentagem, facilitando a comparação entre diferentes modelos.

O MedAE calcula a mediana dos erros absolutos, sendo uma métrica robusta a outliers. O MedAE é calculado da seguinte forma:

$$MedAE = \text{mediana}(|y_i - \hat{y}_i|)$$

Esta métrica é útil em cenários onde se deseja evitar que grandes erros distorçam a avaliação do modelo. O MedAE fornece uma visão das previsões mais típicas, sem ser influenciado por erros extremos.

O AIC é utilizado para comparar modelos, equilibrando o ajuste e a complexidade. Ele penaliza modelos com mais parâmetros para evitar overfitting. O AIC permite comparar modelos não aninhados, sendo especialmente útil em situações com dados limitados, como ao avaliar modelos SARIMA [Zajic 2022].

Essas métricas são utilizadas para comparar o desempenho de diferentes modelos de previsão, como o SARIMA e o XGBoost, proporcionando uma avaliação mais completa da precisão e consistência das previsões no setor varejista.

3. Metodologia

Este estudo adota uma abordagem quantitativa, utilizando métodos estatísticos e técnicas de aprendizado de máquina para prever séries temporais de receita de uma varejista. O objetivo principal é comparar o desempenho de dois modelos preditivos: SARIMA e XGBoost.

São coletados dados mensais de 2020 a 2024, mas os dados de 2020 são descartados devido à pandemia de COVID-19, que causou distorções nas vendas e variações atípicas na receita. Portanto, são utilizados dados a partir de 2021, contendo informações sobre os itens vendidos e suas quantidades. Realiza-se um pré-processamento dos dados, no qual é utilizada uma tabela com o histórico de preços para calcular a receita de cada produto. Após essa etapa, é feita uma categorização manual dos produtos, uma vez que inicialmente eles não possuíam uma classificação definida. Esse processo visa organizar os itens em categorias específicas, permitindo uma análise mais detalhada das receitas por segmento de produto.

Como resultado, é criada uma tabela consolidada com dados de receitas mensais, segmentados em 15 categorias de produtos, para o período de janeiro de 2021 a junho de 2024, totalizando 42 meses. As categorias utilizadas na análise estão apresentadas na Tabela 3.

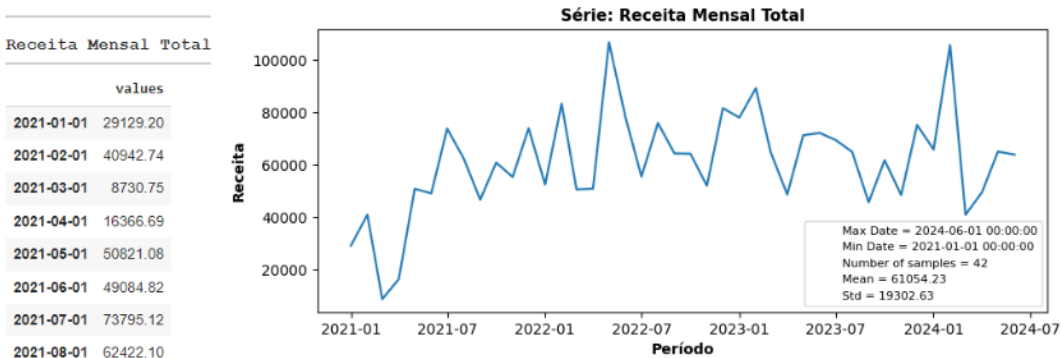
Tabela 3. Categorias de produtos utilizadas na análise.

Categorias de Produto				
presente	total	enfeite	material-escolar	utilidade
acessorio	brinquedo	escritorio	calcado	vestuario
eletronico	pet	natal	doce	beleza-e-estetica

A Figura 1 exibe um gráfico da evolução da receita total da varejista ao longo do período analisado, destacando padrões sazonais e variações temporais.

A análise exploratória é realizada por meio de gráficos de linha e das funções de autocorrelação (ACF) e autocorrelação parcial (PACF), com o objetivo de identificar padrões e sazonalidades nas séries temporais. O teste de Dickey-Fuller Aumentado (ADF) é aplicado para verificar a estacionariedade dos dados.


Figura 1. Receita total mensal da varejista.



No modelo SARIMA, uma estimativa inicial é obtida utilizando o método autoarima. No entanto, como os resultados não são satisfatórios, os parâmetros são ajustados com base na análise das funções ACF e PACF, por meio de uma abordagem de força bruta. Diversas combinações de parâmetros são testadas para minimizar o AIC. As previsões são feitas para horizontes de 1 e 3 meses, tanto para a receita total quanto para cada categoria de produto. Utiliza-se uma janela deslizante, onde os dados dos 30 meses anteriores são usados para prever o valor do mês seguinte. A cada iteração, a janela se desloca, incorporando o mês mais recente e descartando o mais antigo, garantindo que o modelo seja sempre atualizado com os dados mais recentes.

No modelo XGBoost, são avaliados diferentes números de lags (de 1 a 12 meses) para capturar padrões temporais. O modelo é ajustado com 50 estimadores e uma semente fixa para garantir a reprodutibilidade. As previsões são realizadas para 1 e 3 meses, testando diferentes combinações de lags para maximizar a precisão, com o uso da janela deslizante. Assim como no modelo SARIMA, a cada iteração, a janela é movida para incluir os dados mais recentes.

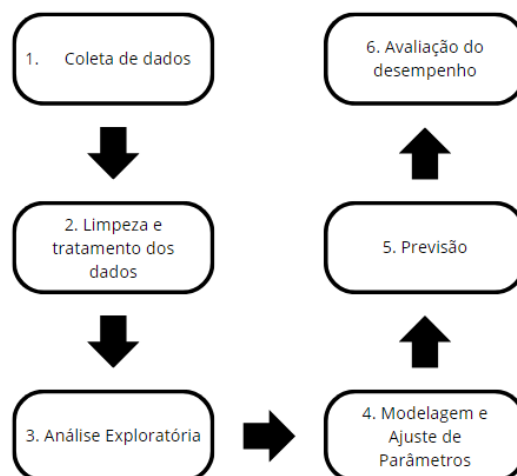
Podemos observar a janela deslizante na figura 2.



A avaliação dos modelos é feita com base nas métricas RMSE, MAPE e MedAE. Estatísticas descritivas das métricas, como desvio padrão, valores mínimos e máximos, são calculadas para fornecer uma análise detalhada da variabilidade das previsões.

Os resultados das previsões para horizontes de 1 e 3 meses são comparados entre os modelos SARIMA e XGBoost. A Figura 3 apresenta um fluxograma que ilustra a metodologia adotada.

Figura 3. Fluxograma da metodologia.



4. Resultados e Discussão

Nesta seção, são apresentados os resultados da modelagem e previsão das receitas mensais, incluindo testes de estacionariedade, análises de autocorrelação e seleção de parâmetros para definir o melhor modelo para cada categoria.

O teste de estacionariedade, realizado com o método ADF, aponta valores abaixo de 0,05 como indicativos de séries estacionárias. Conforme a Tabela 4, as categorias Natal, Doce e Beleza e Estética apresentam comportamento não estacionário, enquanto as demais são consideradas estacionárias.

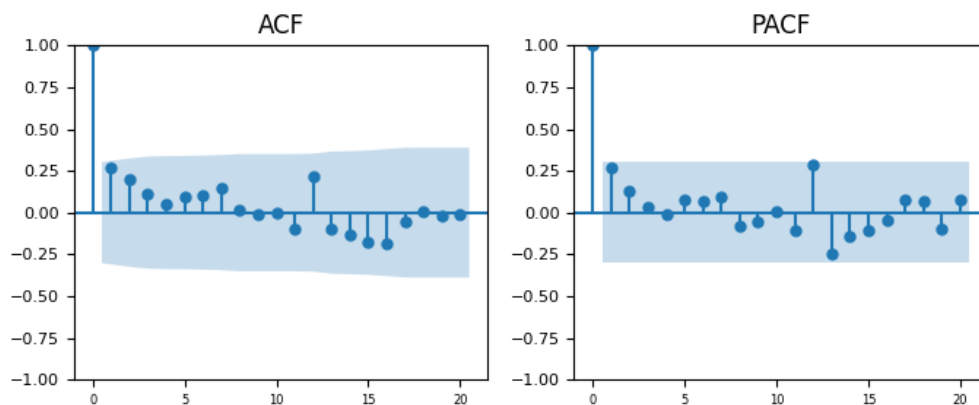
Tabela 4. Resultados do Teste de Estacionariedade (Teste ADF) por Categoria

Categoria	Estacionária	p-value
Presente	True	0.00
Total	True	0.00
Enfeite	True	0.00
Material Escolar	True	0.00
Utilidade	True	0.00
Acessório	True	0.00
Brinquedo	True	0.00
Escritório	True	0.00
Calçado	True	0.00
Vestuário	True	0.00
Eletrônico	True	0.00
Pet	True	0.01
Natal	False	0.32
Doce	False	0.67
Beleza e Estética	False	0.70

A análise das funções de Autocorrelação (ACF) e Autocorrelação Parcial (PACF) é realizada para todas as categorias [Jhonatan 2024]. A Figura 4 mostra a análise da

receita total, na qual não se observam padrões claros de correlação significativa nem indicações de sazonalidade definida.

Figura 4. Análise do ACF e PACF da Receita Total.



Após a seleção dos parâmetros a partir das análises de ACF e PACF, os modelos SARIMA são ajustados para cada categoria. A Tabela 5 apresenta os melhores modelos selecionados com base no critério AIC. Com esses modelos, são feitas as previsões de curto prazo (1 mês) e médio prazo (3 meses), utilizando 42 meses de dados. Observa-se que os modelos ajustados variam em complexidade, refletindo as diferentes dinâmicas e comportamentos das séries temporais de cada categoria.

A previsão de um mês do modelo SARIMA, apresentada na Tabela 6, mostra menores níveis de erro, indicando maior precisão nas previsões de curto prazo.

Por outro lado, a previsão de três meses, mostrada na Tabela 7, apresenta um erro maior em comparação com a previsão de um mês.

Tabela 5. Melhores Modelos SARIMA por Categoria, com base no AIC

Categoria	Best-AIC-Model	AIC
Material Escolar	((1, 1, 2), (1, 0, 0, 12))	63.348496
Doce	((0, 1, 1), (0, 0, 0, 12))	600.012929
Beleza e Estética	((0, 1, 1), (1, 0, 0, 12))	632.405302
Natal	((0, 1, 2), (1, 0, 0, 12))	633.328987
Calçado	((1, 1, 1), (0, 0, 0, 12))	637.985288
Escritório	((0, 1, 1), (1, 0, 0, 12))	656.753346
Presente	((0, 0, 2), (1, 0, 0, 12))	672.591375
Pet	((0, 1, 2), (0, 0, 0, 12))	674.043816
Eletrônico	((2, 1, 2), (1, 0, 0, 12))	701.318396
Enfeite	((0, 1, 1), (1, 0, 0, 12))	712.895693
Utilidade	((2, 1, 0), (1, 0, 0, 12))	745.951820
Brinquedo	((0, 1, 2), (1, 0, 0, 12))	759.414440
Acessório	((0, 1, 1), (1, 0, 0, 12))	787.209125
Vestuário	((0, 1, 2), (1, 0, 0, 12))	847.729709
Total	((0, 1, 1), (1, 0, 0, 12))	923.199794

Tabela 6. Previsão de 1 Mês (SARIMA), por categoria.

Categoria	Order	Seasonal Order	AIC	RMSE	MAPE	MedAE
Calçado	(1, 1, 1)	(0, 0, 0, 12)	637.99	448.15	0.15	270.61
Utilidade	(2, 1, 0)	(1, 0, 0, 12)	745.95	1391.19	0.16	1280.15
Acessório	(0, 1, 1)	(1, 0, 0, 12)	787.21	2378.67	0.18	2398.99
Escritório	(0, 1, 1)	(1, 0, 0, 12)	656.75	591.31	0.18	495.46
Brinquedo	(0, 1, 2)	(1, 0, 0, 12)	759.41	1555.41	0.20	1508.05
Beleza e Estética	(0, 1, 1)	(1, 0, 0, 12)	632.41	472.97	0.21	279.62
Doce	(0, 1, 1)	(0, 0, 0, 12)	600.01	415.00	0.21	198.15
Eletrônico	(2, 1, 2)	(1, 0, 0, 12)	701.32	1400.17	0.21	898.94
Total	(0, 1, 1)	(1, 0, 0, 12)	923.20	16699.76	0.21	7377.71
Enfeite	(0, 1, 1)	(1, 0, 0, 12)	712.90	875.52	0.22	367.41
Presente	(0, 0, 2)	(1, 0, 0, 12)	672.59	445.10	0.22	419.48
Pet	(0, 1, 2)	(0, 0, 0, 12)	674.04	561.44	0.38	425.53
Material Escolar	(1, 1, 2)	(1, 0, 0, 12)	63.35	6750.39	0.39	2372.82
Vestuário	(0, 1, 2)	(1, 0, 0, 12)	847.73	2651.59	1.11	2008.88
Natal	(0, 1, 2)	(1, 0, 0, 12)	633.33	196.23	4.39	93.36


Tabela 7. Previsão de 3 Meses (SARIMA), por categoria.

Categoria	Order	Seasonal Order	AIC	RMSE	MAPE	MedAE
Total	(0, 1, 1)	(1, 0, 0, 12)	923.20	18461.77	0.23	9153.36
Acessório	(0, 1, 1)	(1, 0, 0, 12)	923.20	52996.07	0.81	50415.49
Material Escolar	(1, 1, 2)	(1, 0, 0, 12)	925.82	54134.53	0.83	50261.14
Brinquedo	(0, 1, 2)	(1, 0, 0, 12)	923.97	57085.11	0.86	51924.64
Utilidade	(2, 1, 0)	(1, 0, 0, 12)	926.89	57152.90	0.86	55613.53
Vestuário	(0, 1, 2)	(1, 0, 0, 12)	923.97	58629.88	0.89	55111.98
Eletrônico	(2, 1, 2)	(1, 0, 0, 12)	924.77	59779.32	0.91	57793.22
Enfeite	(0, 1, 1)	(1, 0, 0, 12)	923.20	61864.12	0.95	59877.58
Escritório	(0, 1, 1)	(1, 0, 0, 12)	923.20	62242.86	0.95	60087.90
Beleza e Estética	(0, 1, 1)	(1, 0, 0, 12)	923.20	62662.21	0.96	60439.89
Presente	(0, 0, 2)	(1, 0, 0, 12)	947.83	62674.48	0.96	60446.89
Calçado	(1, 1, 1)	(0, 0, 0, 12)	929.87	63124.88	0.97	61033.35
Doce	(0, 1, 1)	(0, 0, 0, 12)	927.88	63164.88	0.97	61208.03
Pet	(0, 1, 2)	(0, 0, 0, 12)	930.73	63076.36	0.97	60964.28
Natal	(0, 1, 2)	(1, 0, 0, 12)	923.97	64442.80	0.99	62646.83

Na Figura 5, é apresentado o gráfico das categorias com os piores índices de MAPE, como Natal e Vestuário. Embora as previsões gráficas dessas categorias pareçam razoavelmente boas, os resultados insatisfatórios podem ser atribuídos a fatores específicos de cada uma delas.

Para a categoria Natal, a forte sazonalidade, com picos expressivos de receita nos meses de novembro e dezembro, torna a previsão difícil fora desses períodos. O modelo pode enfrentar desafios para prever com precisão os meses de baixa receita fora da temporada de Natal, o que resulta em grandes erros relativos. Como o MAPE é altamente sensível a erros percentuais, qualquer erro em meses com receitas mais baixas terá um impacto maior na métrica, distorcendo o valor do MAPE, mesmo quando o modelo apresenta boa performance durante os meses de maior receita.


Figura 5. Previsão Mensal de 1 Mês no Modelo SARIMA para as Categorias Natal e Vestuário com Maiores Índices de MAPE



No caso de Vestuário, a maior parte dos produtos dessa categoria está voltada para o inverno, o que faz com que as vendas se concentrem fortemente nesse período. Isso torna a previsão de vendas nos meses fora do inverno mais desafiadora para o modelo. O comportamento sazonal dessa categoria afeta negativamente o MAPE, já que as previsões para os meses com vendas mais baixas (fora da temporada de inverno) geram erros percentuais mais elevados, prejudicando a métrica.

Ambas as categorias, Natal e Vestuário, apresentam grandes variações sazonais que exigem uma modelagem capaz de capturar essas flutuações de maneira precisa. Embora os modelos possam ser eficazes na previsão de picos de receita, eles enfrentam dificuldades em prever os meses de baixa receita, especialmente quando os valores reais são baixos. Isso resulta em MAPE elevados, o que pode não refletir adequadamente a qualidade do modelo, visto que a métrica depende fortemente do erro relativo.

Figura 6. Previsão Mensal de 1 Mês no Modelo SARIMA para as Categorias com os Menores Índices de MAPE



A Figura 6 apresenta os gráficos das categorias Calçado, Utilidade e Acessório, que se destacaram por apresentar bons índices de MAPE e previsões precisas. Isso provavelmente se deve a um padrão de vendas mais estável ao longo do tempo, com variações sazonais menos acentuadas. Esse comportamento facilita a realização das previsões, pois a ausência de grandes flutuações, como as observadas em categorias altamente sazonais

(como Natal e Vestuário), permite que modelos de previsão, como o SARIMA, obtenham resultados mais precisos.

Tabela 8. Melhor configuração de lag para cada categoria no modelo XGBoost e seus respectivos RMSE.

Categoria	Melhor Configuração	RMSE
Doce	(XGBoost, 3)	0.07
Calçado	(XGBoost, 3)	0.09
Escritório	(XGBoost, 4)	0.12
Beleza e Estética	(XGBoost, 2)	0.14
Natal	(XGBoost, 5)	0.14
Pet	(XGBoost, 4)	0.14
Enfeite	(XGBoost, 5)	0.18
Brinquedo	(XGBoost, 7)	0.30
Eletrônico	(XGBoost, 3)	0.30
Presente	(XGBoost, 3)	0.37
Utilidade	(XGBoost, 5)	0.37
Vestuário	(XGBoost, 6)	0.44
Acessório	(XGBoost, 5)	0.89
Material Escolar	(XGBoost, 7)	2.74
Total	(XGBoost, 3)	4.21

Para o modelo XGBoost, testam-se diferentes configurações de lags (variáveis defasadas) com 12 iterações, com o objetivo de identificar a melhor configuração para cada categoria. Durante o processo de análise, avaliam-se os desempenhos de cada configuração de lag, levando em consideração a capacidade de captura de padrões temporais e a minimização do erro nas previsões. Após essa análise, seleciona-se a melhor configuração de lag para cada categoria, conforme apresentado na Tabela 8. Esse processo garante que o modelo esteja ajustado de forma a maximizar a precisão das previsões para as diferentes dinâmicas de cada categoria de receita.

Tabela 9. Métricas do modelo XGBoost 1M por categoria

Categoria	ML Model	Lag	RMSE	MAPE	MedAE
utilidade	XGBOOST	5	1545.51	0.15	775.73
Brinquedo	XGBOOST	7	2364.20	0.18	678.54
Eletrônico	XGBOOST	3	1386.36	0.18	915.72
Total	XGBOOST	3	15559.81	0.18	10222.65
Calçado	XGBOOST	3	548.64	0.19	416.40
Beleza-e-Estética	XGBOOST	2	574.22	0.22	273.64
Doce	XGBOOST	3	480.13	0.26	235.50
Escritório	XGBOOST	4	831.99	0.28	789.61
Acessório	XGBOOST	5	4208.46	0.30	2576.71
Pet	XGBOOST	4	593.00	0.38	533.44
Enfeite	XGBOOST	5	1369.61	0.44	1040.29
Material-Escolar	XGBOOST	7	9918.53	0.53	2756.81
Presente	XGBOOST	3	1823.11	0.62	441.70
Natal	XGBOOST	5	538.38	3.87	71.38
Vestuário	XGBOOST	6	16176.60	5.30	13204.83


As previsões são realizadas com a melhor configuração de lag para cada categoria.

Nas tabelas 9 e 10, observa-se que as previsões de médio prazo (3 meses) apresentam resultados piores em comparação com as de curto prazo (1 mês), evidenciado pelos maiores valores de RMSE e MAPE. Esse padrão é esperado, pois as previsões de curto prazo são geralmente mais precisas devido à maior disponibilidade de dados recentes e menor incerteza. Além disso, as previsões de 1 mês são mais confiáveis devido à proximidade com os dados históricos, o que reduz a incerteza associada às flutuações de curto prazo. Já as previsões de 3 meses envolvem uma maior projeção de futuro, aumentando a complexidade do modelo ao tentar capturar tendências que podem mudar ao longo do tempo.

Tabela 10. Métricas do modelo XGBoost 3M por categoria

Categoria	ML Model	Lag	RMSE	MAPE	MedAE
Calçado	XGBOOST	3	534.88	0.19	283.01
Total	XGBOOST	3	16900.37	0.19	9806.70
Utilidade	XGBOOST	5	2021.56	0.22	1260.80
Beleza-e-Estética	XGBOOST	2	584.76	0.25	374.81
Brinquedo	XGBOOST	7	3117.78	0.26	1509.62
Eletrônico	XGBOOST	3	1860.56	0.26	1239.11
Escritório	XGBOOST	4	836.67	0.28	591.58
Doce	XGBOOST	3	582.24	0.34	487.44
Acessório	XGBOOST	5	5793.29	0.44	4355.00
Enfeite	XGBOOST	5	1463.49	0.44	856.19
Pet	XGBOOST	4	681.54	0.49	500.29
Material-Escolar	XGBOOST	7	12338.95	0.53	1533.81
Presente	XGBOOST	3	2976.34	1.07	1178.49
Vestuário	XGBOOST	6	16375.80	7.40	14360.68
Natal	XGBOOST	5	987.17	7.60	63.34

Figura 7. Previsão Mensal de 1 Mês no Modelo XGBoost para as Categorias com os Menores Índices de MAPE



Na Figura 7, as previsões de um mês para as categorias Vestuário e Natal, geradas pelo modelo XGBoost, apresentam resultados visivelmente piores em comparação com o modelo SARIMA, tanto graficamente quanto no MAPE, indicando um desempenho insatisfatório. O MAPE elevado reflete erros percentuais significativos, especialmente em meses de baixa receita, o que impacta negativamente na métrica. Apesar da seleção de

diferentes configurações de lags no modelo XGBoost, o modelo não consegue capturar adequadamente as flutuações sazonais intensas dessas categorias, contribuindo para os erros elevados. Em contraste, o modelo SARIMA lida de forma mais eficaz com essas variações sazonais, resultando em previsões mais ajustadas e um desempenho superior.

Tabela 11. Melhores Modelos para Previsão de 1 Mês e 3 Meses

Categoria	Modelo 1M	MAPE 1M	Modelo 3M	MAPE3M
Calçado	SARIMA(1, 1, 1)(0, 0, 0, 12)	0.15	XGBOOST_3	0.19
Utilidade	SARIMA(2, 1, 0)(1, 0, 0, 12)	0.16	XGBOOST_5	0.22
Acessório	SARIMA(0, 1, 1)(1, 0, 0, 12)	0.18	XGBOOST_5	0.44
Eletrônico	XGBOOST_3	0.18	XGBOOST_3	0.26
Escritório	SARIMA(0, 1, 1)(1, 0, 0, 12)	0.18	XGBOOST_4	0.28
Total	XGBOOST_3	0.18	XGBOOST_3	0.19
Brinquedo	SARIMA(0, 1, 2)(1, 0, 0, 12)	0.20	XGBOOST_7	0.26
Beleza-e-Estética	SARIMA(0, 1, 1)(1, 0, 0, 12)	0.21	XGBOOST_2	0.25
Doce	SARIMA(0, 1, 1)(0, 0, 0, 12)	0.21	XGBOOST_3	0.34
Enfeite	SARIMA(0, 1, 1)(1, 0, 0, 12)	0.22	XGBOOST_5	0.44
Presente	SARIMA(0, 0, 2)(1, 0, 0, 12)	0.22	XGBOOST_3	1.07
Pet	SARIMA(0, 1, 2)(0, 0, 0, 12)	0.38	XGBOOST_4	0.49
Material-Escolar	SARIMA(1, 1, 2)(1, 0, 0, 12)	0.39	XGBOOST_7	0.53
Vestuário	SARIMA(0, 1, 2)(1, 0, 0, 12)	1.11	XGBOOST_6	7.40
Natal	SARIMA(0, 1, 2)(1, 0, 0, 12)	4.39	XGBOOST_5	7.60

Os resultados indicam que, embora o SARIMA tenha bom desempenho para o curto prazo, sua precisão diminui nas previsões de médio prazo, especialmente em séries sazonais. Por outro lado, o XGBoost demonstra ser uma alternativa eficaz para previsões de médio prazo, sugerindo que a utilização conjunta dos dois modelos pode trazer melhores resultados.

5. Conclusão

Este trabalho teve como objetivo analisar e prever as receitas mensais de diversas categorias do varejo, utilizando os modelos SARIMA e XGBoost. A pesquisa abordou o problema de previsão de receitas em um contexto de dados mensais e variáveis sazonais, oferecendo suporte ao planejamento estratégico e à tomada de decisões no setor varejista.

As séries temporais de receitas no varejo apresentam desafios significativos devido à imprevisibilidade das variações de demanda, alterações nos preços, substituição de produtos e influência de fatores externos. Essas dinâmicas tornam a modelagem de receitas uma tarefa complexa, já que pequenos desvios podem impactar consideravelmente os resultados.

Os modelos testados apresentaram desempenhos distintos dependendo do horizonte de previsão. Na previsão de um mês, o modelo SARIMA demonstrou maior precisão, evidenciando sua capacidade de capturar padrões de curto prazo com base nas características sazonais e tendências históricas das séries. Em contrapartida, o XGBoost se destacou na previsão de três meses, beneficiando-se de sua flexibilidade em incorporar lags e identificar relações complexas nos dados, mesmo em horizontes mais longos. Essa diferença de desempenho reflete as particularidades de cada abordagem: enquanto o SARIMA se baseia em suposições estatísticas sobre a estrutura temporal, o XGBoost é

menos dependente dessas suposições e pode se adaptar melhor a mudanças e padrões não lineares ao longo do tempo.

Ainda assim, os desempenhos variaram entre categorias. Categorias como Calçado, Brinquedo e Beleza-e-Estética tiveram previsões mais próximas dos valores reais, enquanto Natal e Vestuário apresentaram maiores dificuldades. No caso do Natal, a alta sazonalidade e a concentração de vendas no final do ano limitaram a capacidade dos modelos de capturar padrões consistentes. Em Vestuário, variáveis externas, como o clima, desempenham um papel determinante, e a ausência dessas informações reduziu a precisão das previsões.

Essas limitações destacam a necessidade de ajustes e complementos nos modelos. Para categorias como Natal, a inclusão de dados relacionados a promoções ou eventos sazonais pode melhorar os resultados. Em Vestuário, variáveis como temperaturas médias ou tendências de moda poderiam aumentar a precisão das previsões. Apesar dessas dificuldades, os modelos mostraram-se úteis para prever receitas totais e categorias com padrões de vendas mais regulares. Essa aplicabilidade é valiosa para o planejamento de estoques, ajudando a evitar excessos ou faltas, além de facilitar a projeção de promoções e a gestão orçamentária com base em tendências identificadas.

Os resultados reforçam que, embora os modelos apresentem limitações em algumas categorias, eles ainda são ferramentas relevantes para o planejamento em contextos de menor variabilidade. Para categorias com maior imprevisibilidade, é necessário explorar abordagens complementares, como a introdução de variáveis exógenas que considerem fatores econômicos, sociais e de mercado. Modelos híbridos que combinam técnicas estatísticas e aprendizado de máquina também podem capturar diferentes aspectos dos padrões de receita. Além disso, a análise de granularidades mais detalhadas, como dados diários ou semanais, poderia revelar variações mais sutis, aumentando a precisão das previsões.

Este trabalho destaca tanto o potencial quanto as limitações das técnicas utilizadas, apontando caminhos para melhorias e inovações futuras. Ele contribui para a aplicação prática de métodos de previsão de receitas no varejo, oferecendo insights para categorias estáveis e sinalizando a necessidade de análises mais abrangentes para produtos mais voláteis. As investigações futuras podem incluir técnicas mais avançadas, como redes neurais e métodos de deep learning, ampliando a precisão das previsões em cenários complexos e trazendo benefícios diretos ao planejamento estratégico no varejo.

Referências

- Botelho, D. and Guissoni, L. (2016). Varejo: competitividade e inovação. *Revista de Administração de Empresas*, 56(6):596–599.
- Box, G. E., Jenkins, G. M., Reinsel, G. C., and Ljung, G. M. (2015). *Time series analysis: forecasting and control*. John Wiley & Sons.
- Chen, T. and Guestrin, C. (2016). Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, pages 785–794.
- de Oliveira, R., Albarracín, O. Y., and da Silva, G. R. (2024). Introdução às séries temporais: Uma abordagem prática em python. *GitHub*.

- Eda Kavlakoglu, E. R. (2024). O que é o xgboost? Disponível em: <https://www.ibm.com/br-pt/topics/xgboost>. Acesso em: 12 nov. 2024.
- Holanda, B. M. S., dos Santos, R. H., and dos Santos, W. A. (2022). Gestão e organização do estoque em empresas de varejo: um estudo comparativo de duas empresas de loanda, paraná. *Desenvolve Revista de Gestão do Unilasalle*, 11(3).
- Holbrook, R. (2020). Time series as features. Disponível em: <https://www.kaggle.com/code/ryanhobbrook/time-series-as-features>. Acesso em: 19 de novembro de 2024.
- Hyndman, R. (2018). *Forecasting: principles and practice*. OTexts. Time series patterns.
- Jhonatan (2024). Análise e previsão de receitas no varejo: comparação entre modelos sarima e xgboost. Disponível em: <https://github.com/jhonatan95w/SeriesTemporais-Varejo>. Acesso em: 19 de novembro de 2024.
- Las Casas, A. L. and Garcia, M. T. (2007). Estratégias de marketing para varejo. *Inovações e diferenciaciones estrategicas que fazem a diferenca no marketing de varejo*. Sao Paulo: Novatec.
- Oliveira, A. d. S. d. et al. (2024). Análise comparativa de modelos de previsão para receitas correntes mensais do estado de alagoas: abordagens econométricas e redes neurais. *ufal*.
- Pinto, R. A. Q., Tortato, U., Da Veiga, C. P., and Catapan, A. (2013). Gestão de estoque e lean manufacturing: estudo de caso em uma empresa metalúrgica. *Revista Administração em Diálogo-RAD*, 15(1).
- Santos, A. M. M. M. and Costa, C. S. (1997). Características gerais do varejo no brasil. *BNDES*.
- Scikit-learn (2024). Metrics and scoring: quantifying the quality of predictions. Disponível em: https://scikit-learn.org/1.5/modules/model_evaluation.html. Acesso em: 12 de novembro de 2024.
- Silveira, I. V. et al. (2019). Modelo de previsão de demanda com o uso de aprendizado supervisionado de máquina: um estudo de caso em uma empresa de varejo. *UFSC*.
- Zajic, A. (2022). What is akaike information criterion (aic)? Disponível em: <https://builtin.com/data-science/what-is-aic>. Acesso em: 19 nov. 2024.